



RA DAR - платформа для выявление и оценка горячих новостей в финансах

Команда

Самый недообученный ML в Вавилоне



Проблемы

Компоненты

Формула

01

Шум, дубли и устаревание информации

**Novelty**

новизна/внеплановость

02

Быстрые вирусные всплески упоминаний

**Burst**

скорость/масштаб

03

Сомнительные и анонимные источники

**Credibility**

подтверждения

04

Локальные новости без отраслевого контекста

**Breadth**

охват активов/регионов

05

Нет реального рыночного эффекта

**Materiality**

цена/волатильность

$$\text{Hotness} = w_1 \text{ Novelty} + w_2 \text{ Burst} \\ + w_3 \text{ Credibility} + w_4 \text{ Breadth} \\ + w_5 \text{ Materiality}$$

Источники

Подобраны на основе мнения экспертов

Forbes

МОЕХ

РБК



интерфакс

газета.ru

ИЗВЕСТИЯ .RULONDON
STOCK
EXCHANGE

Более 50 телеграм каналов, рекомендованных опытными трейдерами


Хранение новостей

1. Выделяем основные сущности
2. Проверяем новизну
3. Проверяем связана ли новость с финансами

Стек технологий:

- NLP Enrichment.
- Clustering / Dedup
- Vector DB / Search
- Graph Layer
- Reranker

Источники



json file

Валидация новостей

GPU
векторизацияОтправка
данных в
векторную БДГенерация черновика
статьиОбращения в
mini app в
телеграммеОбращение в
векторную
бдГибридный
поиск

1. Поиск по фильтрам
2. Поиск по hotness и date
3. reranker

Новости с
метаданнымиПередача
по api в
openaiЧерновик
статьиОтображение у
пользователя

Черновик

Россия: рекорд Сбербанка, дивиденды Газпрома, МТС усиливает B2B — сигнал отраслевого тренда

КЛЮЧЕВЫЕ МОМЕНТЫ

- Сбербанк: чистая прибыль 389 млрд ₽; акции +3,2% после отчётности.
- Герман Греф: планы увеличить дивиденды (заявление руководства).

ОСНОВНОЙ ТЕКСТ

- Сбербанк сообщил о чистой прибыли 389 млрд ₽; акции прибавили около 3,2% после публикации отчётности. По словам Германа Грефа, банк планирует увеличить дивиденды....



Соцпост

Российские голубые фишки на радаре: Сбербанк — рекордная чистая прибыль 389 млрд ₽, акции +3,2% после отчётности; Герман Греф заявил о планах повысить дивиденды...



Алерт

РФ: Сбербанк — чистая прибыль 389 млрд ₽ (акции +3,2%); Газпром — дивиденды 52 ₽/акцию; МТС — новые корпоративные тарифы, B2B +23%. Тренд: рост дивидендов и фокус телекомов на корпоративном спросе.

ИСТОЧНИКИ

- Сбербанк показал рекордную прибыль
- МТС усиливает позиции в корпоративном секторе
- Газпром порадовал акционеров



Сюжет №1 - реальный

Банк России снизил ключевую ставку до 17% (12 сен 2025)

Официальное решение регулятора, влияющее на стоимость денег по всей экономике; снижение на 100 б.п. оказалось скромнее ожиданий, что само по себе новость для рынка.

$$\text{Hotness}(0.82) = w_1 \text{Novelty}(0.75) + w_2 \text{Burst}(0.85) + w_3 \text{Credibility}(1) + w_4 \text{Breadth}(0.85) + w_5 \text{Materiality}(0.55)$$

ИСТОЧНИКИ

- Пресс-релиз ЦБ РФ (англ.) — решение по ключевой ставке.
- Заявление Э. Набиуллиной по итогам заседания.
- Reuters: «Central bank cuts to 17% (меньше ожиданий)».

Сюжет №2 - ложноположительный

В ряде соц-каналов ходили посты про «спецдивиденд», но официально: в бюджете-2025 дивиденд не заложен, а совет директоров не рекомендовал дивиденды по итогам-2024.

$$\text{Hotness}(0.31) = w_1 \cdot \text{Novelty}(0.4) + w_2 \cdot \text{Burst}(0.45) + w_3 \cdot \text{Credibility}(0.23) + w_4 \cdot \text{Breadth}(0.3) + w_5 \cdot \text{Materiality}(0.1)$$

ИСТОЧНИКИ

- Минфин: в бюджете-2025 не планируются дивиденды Газпрома.
- Reuters: «Gazprom scraps dividend on 2024 results»
- Refinitiv/Reuters (через TradingView): та же новость.

Цель/источники

Решение

Пример сюжетов

Эффективность

Выводы

Время поиска новости в БД

менее 3 секунд



Генерация черновика

около 40 секунд



Частота парсинга

раз в 5 минут



Эффективность

01

Фильтрация во время парсинга: проверяем имеет ли отношение новость к финансам, смотрим новизну по ряду ключевых слов:

новизна → MoEX: торги **приостановлены** на рынке облигаций с 11:10 MSK

повтор → Компания подтвердила **ранее** объявленные условия сделки

02

Группируем новости в кластеры событий по сущностям (тикеры/регулятор/страна), времени и косинусной близости эмбедингов. Один проход LLM — на кластер, а не на каждую новость, что сокращает кол-во операций по определению hotness

03

Векторная БД + BM25 и фильтры по времени/тикерам дают миллисекундный retriever для UI и RAG.

04

Сохраняем запросы пользователей и ответы в базе данных, при повторном обращении с аналогичным запросом быстро достаём ответ, снижая время ожидания и сокращая запрос в openai

01

Ранжируем источники по типам (regulator/exchange/issuer/trader) и оцениваем credibility источника с весом, который учитывается в итоговом hotness

02

Наличие биржевого/регуляторного документа (тип формы, номер дела/решения) создаёт в графе ребро «Anchor», повышает Credibility и статус сюжета (Observed → Confirmed).

03

Фразы «according to sources/по данным источников/слухи», кликбейт/ALL CAPS, отсутствие чисел/дат → маркируются как Unverified

04

Храним метаданные для кластеров и связь между новостями, чтобы отсеить устаревший метриал

Дезинформация и устаревшие материалы

MVP - то что уже можно использовать

Сбор данных	Обработка	Кластеризация	Хранение данных	Генерация
Парсинг официальных новостных каналов и индивидуальных тг каналов	Фильтруем данные на наличие признаков новизны в новости, отношения к финансовому сектору, выделяем основные сущности	Дедуплецируем новости сравнивая с существующими кластерами по косинусной близости Рассчитываем hotness для кластеров на основе количественных признаков	Храним всю формулировку новости с метаданными, сущностями и hotness Используем гибридный поиск для быстрого обращения к новости	Генерируем черновик в pdf формате, где выделяем ключевые новости по порогу hotness, генерируем несколько текстов для сайта и канала
Backlog				
Парсинг твиттера Поможет оценить отношение людей к новости и вовлеченность		Использовать алгоритм саморазжигающегося процесса Хокса для оценки Burst Оценка credibility для каждого источника на основе истории новостей и влияния на цены Оценка Materiality на основе тональности текста		Добавить визуализацию данных на основе финансовых инструментов, упомянутых в новости Пытаемся предсказать что будет дальше на основе цепочки новостей для определенных компаний/секторов

Самый недообученный ML в Вавилоне

Ссылка на гитхаб



Ссылка на демо

